

**ESTÁCIO DE SÁ
FLORIANÓPOLIS**

Uso de Antidepressivos pós-pandemia no BR

Alunos: Isadora Cândido, Gabriel Gusmão, Ruth Cavalcante, Nicollas da Silva, Enzo Laranjeira

Professor: Vagner Cordeiro

Disciplina: Big Data

2026

Florianópolis/SC

Sumário

1. DIAGNÓSTICO E TEORIZAÇÃO

- 1.1. Identificação das partes interessadas e parceiros
- 1.2. Problemática e/ou problemas identificados
- 1.3. Justificativa
- 1.4. Objetivos/resultados/efeitos a serem alcançados
- 1.5. Referencial teórico

2. PLANEJAMENTO E DESENVOLVIMENTO DO PROJETO

- 2.1. Plano de trabalho
- 2.2. Descrição da forma de envolvimento do público participante
- 2.3. Grupo de trabalho
- 2.4. Metas, critérios ou indicadores de avaliação do projeto
- 2.5. Recursos previstos
- 2.6. Detalhamento técnico do projeto

3. ENCERRAMENTO DO PROJETO

- 3.1. Relato Coletivo
 - 3.1.1. Avaliação de reação da parte interessada
- 3.2. Relato de Experiência Individual
 - 3.2.1. Contextualização
 - 3.2.2. Metodologia
 - 3.2.3. Resultados e Discussão
 - 3.2.4. Reflexão Aprofundada
 - 3.2.5. Considerações Finais

1. DIAGNÓSTICO E TEORIZAÇÃO

1.1. Identificação das partes interessadas e parceiros

O presente projeto possui caráter analítico e investigativo, fundamentado na exploração de dados públicos secundários referentes ao consumo de antidepressivos no Brasil após a pandemia de COVID-19. Pela natureza da proposta, que se apoia em bases de dados já consolidadas e disponibilizadas por instituições oficiais, não houve a definição de um público sociocomunitário direto, tampouco a celebração de termos de cooperação formais com parceiros externos.

Apesar de não haver um público-alvo direto, identificam-se partes interessadas indiretas relevantes, sobre as quais os resultados do projeto podem produzir impacto:

- Gestores e formuladores de políticas públicas de saúde, que podem se beneficiar de análises sobre tendências de consumo de psicofármacos para subsidiar decisões.
- Profissionais da saúde mental (psiquiatras, psicólogos, farmacêuticos), interessados em compreender o cenário do uso de antidepressivos no país.
- Pesquisadores e estudantes da área de saúde e tecnologia da informação, que podem utilizar os resultados como ponto de partida para novas investigações.
- A sociedade brasileira em geral, principal beneficiária de políticas de saúde mental mais bem informadas por dados.

As fontes de dados utilizadas — FIOCRUZ, Conselho Federal de Farmácia (CFF) em parceria com a IQVIA, e estudos acadêmicos publicados — são, em si, parceiros institucionais indiretos, pois disponibilizam publicamente as informações que sustentam toda a análise.

1.2. Problemática e/ou problemas identificados

A pandemia de COVID-19 desencadeou uma das mais graves crises de saúde mental já registradas no Brasil contemporâneo. O isolamento social, as incertezas econômicas, o luto coletivo e as mudanças abruptas na rotina pessoal e profissional contribuíram para o aumento expressivo de quadros de ansiedade, depressão e outros transtornos psiquiátricos. Como consequência direta, observou-se um crescimento significativo no consumo de antidepressivos no país.

A problemática que motiva este projeto reside na dificuldade de obter, de forma consolidada e acessível, uma visão analítica clara sobre esse fenômeno. As informações encontram-se dispersas entre relatórios institucionais, bases de dados de vendas e artigos acadêmicos, dificultando a compreensão integrada do problema. Surgem questões importantes que carecem de resposta sistemática:

- Qual a real dimensão do aumento no consumo de antidepressivos no período pós-pandemia?
- Quais perfis demográficos e socioeconômicos foram mais afetados?
- Como o consumo se distribui entre os diferentes grupos clínicos (depressão, ansiedade, transtornos correlatos)?

- É possível projetar tendências futuras de consumo a partir do comportamento observado?

A ausência de uma análise integrada e visualmente acessível desses dados dificulta tanto a tomada de decisão por parte de gestores quanto a compreensão pública do fenômeno.

1.3. Justificativa

A escolha do tema se justifica pela sua relevância social e pela aderência ao curso de Big Data. Do ponto de vista social, compreender o aumento do consumo de antidepressivos é fundamental para o planejamento de políticas públicas de saúde mental, alocação de recursos e desenho de campanhas de conscientização. Trata-se de uma demanda concreta da realidade brasileira pós-pandemia.

Do ponto de vista acadêmico, o projeto materializa de forma prática os principais conceitos abordados na disciplina de Big Data: ingestão e armazenamento de grandes volumes de dados, construção de pipelines automatizados, tratamento e padronização de dados, aplicação de modelos de Machine Learning para identificação de padrões e previsão de tendências, e por fim a visualização interativa dos resultados. A escolha de ferramentas amplamente adotadas no mercado — Databricks, Power BI, Scikit-learn e Prophet — também alinha a formação técnica do grupo às demandas profissionais reais.

A motivação do grupo de trabalho parte do interesse comum em aplicar técnicas modernas de análise de dados a um problema de impacto social. Ao mesmo tempo em que se exercitam competências técnicas de processamento e modelagem, lida-se com uma temática sensível e atual, o que reforça o caráter humano da formação tecnológica.

1.4. Objetivos/resultados/efeitos a serem alcançados

O projeto se organiza em torno de três objetivos centrais, descritos a seguir:

- **Analisar o uso de antidepressivos pós-pandemia:** coletar e estudar dados de consumo no período pós-pandemia para entender o impacto psicológico do contexto sanitário sobre o uso de medicamentos.
- **Identificar perfis demográficos dos usuários:** avaliar as características das pessoas que utilizam antidepressivos, considerando idade, gênero e fatores socioeconômicos.
- **Comparar dados antes e depois da pandemia:** examinar as diferenças no consumo de medicamentos entre os períodos pré e pós-pandemia, evidenciando a evolução do fenômeno.

Como resultados concretos esperados, prevê-se a entrega de uma arquitetura de dados funcional (pipeline + tratamento + Machine Learning rodando no Databricks), um conjunto de dashboards interativos no Power BI e modelos preditivos que permitam projetar tendências futuras de consumo. A avaliação será feita pela apresentação dos resultados ao docente e à turma, com validação técnica dos artefatos produzidos.

1.5. Referencial teórico

O referencial teórico utilizado combina relatórios institucionais oficiais e estudos acadêmicos publicados, selecionados pela aderência direta ao recorte temático do projeto:

FUNDAÇÃO OSWALDO CRUZ — FIOCRUZ (2021). O relatório da FIOCRUZ sobre o impacto da pandemia na saúde mental dos brasileiros constitui referência central para compreender a dimensão coletiva do problema. O estudo evidencia o crescimento dos quadros de ansiedade, depressão e estresse pós-traumático durante e após o período crítico da pandemia, oferecendo o pano de fundo epidemiológico necessário ao projeto.

CONSELHO FEDERAL DE FARMÁCIA — CFF, em parceria com a IQVIA (2023). Os dados do CFF e da IQVIA sobre vendas de medicamentos psiquiátricos fornecem a base quantitativa essencial para a análise. A IQVIA é uma referência mundial em informações sobre o mercado farmacêutico, e seus números permitem dimensionar o crescimento real do consumo de antidepressivos no período estudado.

CORREIA, R. de M. et al. (2023). A análise comparativa do uso de psicofármacos nos períodos pré e pós-pandemia, publicada pelos autores, dialoga diretamente com o terceiro objetivo do projeto. O estudo apresenta metodologia e achados que servem de parâmetro comparativo para os resultados que se pretende obter.

BOAVIAGEM, K. M.; NOGUEIRA, J. R. B. (2021). A análise demográfica e socioeconômica do uso e do acesso a medicamentos antidepressivos no Brasil oferece o referencial necessário para o segundo objetivo do trabalho, fornecendo critérios e variáveis relevantes para o recorte de perfis dos usuários.

Em conjunto, esses quatro referenciais oferecem cobertura tanto da dimensão epidemiológica (FIOCRUZ) quanto da dimensão mercadológica (CFF/IQVIA), da análise temporal comparativa (Correia et al.) e da análise demográfica (Boaviagem & Nogueira). Essa combinação sustenta teórica e empiricamente todas as etapas analíticas do projeto.

2. PLANEJAMENTO E DESENVOLVIMENTO DO PROJETO

2.1. Plano de trabalho

O plano de trabalho foi estruturado em forma de cronograma com etapas sequenciais, alinhadas aos procedimentos de ensino-aprendizagem da disciplina. A organização foi feita de modo a permitir o acompanhamento contínuo dos avanços do grupo e a entrega dos artefatos parciais conforme os prazos estabelecidos pelo docente. O cronograma consolidado é apresentado a seguir:

Data	Etapas / Atividade	Responsáveis
11/05 a 15/05	Coleta de dados nas fontes definidas (FIOCRUZ, CFF/IQVIA, artigos acadêmicos).	Grupo todo
17/05	Divisão de tarefas e definição de responsabilidades técnicas de cada membro.	Grupo todo
19/05	Construção do pipeline de dados e tratamento inicial no Databricks.	Enzo Laranjeira
24/05	Teste inicial no Power BI com os primeiros dados tratados.	Gabriel Gusmão
25/05	Montagem da primeira apresentação (objetivos, arquitetura, fontes).	Isadora Cândido / Nicollas da Silva
02/06	Primeira apresentação do projeto ao docente e à turma.	Grupo todo
03/06	Finalização dos modelos de Machine Learning (Scikit-learn e Prophet).	Ruth Cavalcante
07/06	Finalização dos dashboards no Power BI.	Gabriel Gusmão
16/06	Entrega final do projeto e do documento completo.	Grupo todo

Cada etapa foi acompanhada por reuniões periódicas do grupo (presenciais e remotas) e por validações conjuntas dos artefatos produzidos, garantindo coerência técnica e alinhamento dos integrantes ao longo do desenvolvimento.

2.2. Descrição da forma de envolvimento do público participante

Pela natureza do projeto, fundamentado em análise de dados públicos secundários disponibilizados por instituições oficiais (FIOCRUZ, CFF/IQVIA) e estudos acadêmicos publicados, não houve coleta primária de dados junto a indivíduos ou comunidades. Trabalhou-se exclusivamente com informações agregadas e anonimizadas, já tratadas pelas fontes originais, sem qualquer interação direta com usuários de antidepressivos.

Por esse motivo, não foi necessária a definição de um público sociocomunitário participante no formato tradicional de extensão, e tampouco a produção de registros de encontros, formulários ou entrevistas. Esse formato se justifica por três razões principais:

- Eticidade da abordagem: ao utilizar exclusivamente dados secundários agregados e anonimizados, o projeto evita riscos de exposição de pessoas em situação de vulnerabilidade psicológica.
- Aderência ao escopo da disciplina: o foco da disciplina de Big Data está no tratamento, análise e visualização de grandes volumes de dados, sendo o uso de bases públicas a estratégia metodológica mais adequada.
- Viabilidade no prazo: o cronograma de aproximadamente cinco semanas inviabilizaria a aprovação ética e execução de uma coleta primária junto a sujeitos.

Os registros do projeto se concentram, portanto, nos artefatos técnicos produzidos: scripts e notebooks no Databricks, dashboards no Power BI, modelos de Machine Learning, slides da apresentação e este documento final. Esses artefatos compõem o conjunto de evidências da execução do projeto.

2.3. Grupo de trabalho

O grupo é composto por cinco integrantes, com responsabilidades claramente delimitadas conforme as competências técnicas necessárias ao projeto. A divisão garantiu equilíbrio entre as frentes de pesquisa, desenvolvimento técnico e comunicação dos resultados.

Membro	Responsabilidade Principal	Atividades
Gabriel Gusmão	Power BI	Conexão dos dados tratados, construção dos dashboards e visualizações interativas dos resultados.
Enzo Laranjeira	Databricks	Configuração do cluster, construção do pipeline de dados e tratamento (limpeza e padronização).
Ruth Cavalcante	Machine Learning	Implementação dos modelos com Scikit-learn (regressão linear) e Prophet (previsão de séries temporais).
Isadora Cândido	Pesquisa e Documentação	Levantamento bibliográfico, preenchimento dos documentos do projeto e montagem da apresentação.
Nicollas da Silva	Pesquisa e Documentação	Levantamento bibliográfico, preenchimento dos documentos do projeto e montagem da apresentação.

Apesar das responsabilidades específicas, todas as decisões estruturais (arquitetura, escolha de ferramentas, escopo da análise) foram tomadas em conjunto. Os membros

responsáveis pela documentação e apresentação atuaram como elo de integração entre as frentes técnicas, garantindo que o produto final refletisse o trabalho coletivo.

2.4. Metas, critérios ou indicadores de avaliação do projeto

Os critérios de avaliação derivam diretamente dos três objetivos definidos na seção 1.4. Para cada objetivo foi estabelecida uma meta concreta e um indicador verificável, conforme o quadro a seguir:

Objetivo	Meta	Indicador de avaliação
Analisar o uso de antidepressivos pós-pandemia	Consolidar uma base unificada com dados de consumo do período pós-pandemia.	Volume de registros tratados e integrados ao Databricks; validação visual no Power BI.
Identificar perfis demográficos dos usuários	Segmentar o consumo por variáveis demográficas e socioeconômicas (idade, gênero, grupo clínico).	Geração de gráficos de distribuição por grupo clínico e por perfil; análise crítica pelo grupo.
Comparar dados antes e depois da pandemia	Construir comparações temporais que evidenciem o crescimento do consumo.	Modelo de regressão linear (Scikit-learn) com tendência identificada; previsão futura via Prophet.

De forma complementar, considera-se como indicador qualitativo a apresentação técnica dos resultados ao docente, momento em que serão validados o funcionamento da arquitetura de dados, a coerência dos modelos preditivos e a qualidade dos dashboards entregues.

2.5. Recursos previstos

O projeto foi planejado para minimizar dispêndios financeiros, fazendo uso exclusivo de ferramentas gratuitas, versões educacionais ou de uso livre. Os recursos previstos se dividem em três categorias:

Recursos materiais e tecnológicos: Databricks (versão Community Edition ou ambiente educacional fornecido pela instituição), Microsoft Power BI Desktop (versão gratuita), Python e bibliotecas open source (Scikit-learn, Prophet, Pandas), além dos computadores pessoais dos integrantes.

Recursos institucionais: infraestrutura de laboratórios e ambiente de aprendizagem da Estácio de Sá Florianópolis, acesso à biblioteca e aos sistemas acadêmicos, orientação do docente da disciplina.

Recursos humanos: cinco alunos do curso e um professor orientador. Nenhum custo financeiro adicional foi necessário.

Por se tratar de projeto baseado em dados secundários públicos, não houve necessidade de aquisição de licenças, contratação de serviços ou deslocamentos. Esse modelo viabilizou a execução plena do projeto dentro do contexto da disciplina.

2.6. Detalhamento técnico do projeto

A solução de Tecnologia da Informação desenvolvida estrutura-se em uma arquitetura de dados moderna, com três grandes camadas funcionais: processamento (Databricks), análise inteligente (Machine Learning) e visualização (Power BI). Todo o processamento — incluindo o pipeline, o tratamento e a aplicação de modelos preditivos — ocorre dentro do ambiente Databricks. O Power BI atua como camada externa de saída, consumindo os dados já tratados e enriquecidos.

Arquitetura de dados

- **Databricks Cluster:** ambiente de processamento em nuvem, construído sobre Apache Spark, que reúne armazenamento, processamento de grandes volumes de dados e execução de código em um único local.
- **Pipeline de Dados (dentro do Databricks):** fluxo automatizado que coleta os dados das fontes (FIOCRUZ, CFF/IQVIA, artigos) e os transporta para dentro do ambiente.
- **Tratamento de Dados (dentro do Databricks):** limpeza, padronização e remoção de inconsistências, preparando os dados para análise.
- **Machine Learning (dentro do Databricks):** aplicação de algoritmos de aprendizado de máquina sobre os dados tratados.
- **Power BI (saída):** consumo dos dados já tratados e enriquecidos pelo ML, com geração de dashboards e visualizações interativas dos resultados.

Bibliotecas de Machine Learning

Scikit-learn: biblioteca utilizada para análise de dados e construção de modelos preditivos. No projeto, foi empregada para identificar padrões e analisar o crescimento do uso de medicamentos após a pandemia, com aplicação de regressão linear — técnica estatística que descreve a relação entre variáveis traçando a melhor linha reta sobre os dados, permitindo identificar a tendência geral e estimar valores.

Prophet: biblioteca voltada à previsão de séries temporais. Foi utilizada para prever tendências futuras no consumo de medicamentos controlados, aprendendo com o padrão histórico — incluindo tendências e sazonalidades — para projetar como o consumo deve se comportar nos próximos períodos.

Resultado preliminar (Power BI)

Durante o desenvolvimento, foi produzido um primeiro resultado no Power BI: uma análise da distribuição do uso de antidepressivos por grupo clínico, contemplando dez categorias diagnósticas (TOC, TDM, Distímia, Depressão Pós-COVID, Síndrome do Pânico, TAB, TAG, TEPT, Insônia Primária e Ansiedade em Adolescentes). Esse resultado confirma o funcionamento integrado da arquitetura proposta: os dados percorrem corretamente o pipeline, são tratados no Databricks, processados pelos modelos e finalmente apresentados em formato visual no Power BI.

3. ENCERRAMENTO DO PROJETO

3.1. Relato Coletivo

O desenvolvimento do projeto representou, para o grupo, uma experiência muito interessante e enriquecedora. A oportunidade de manusear na prática ferramentas de Big Data — Databricks, Power BI, bibliotecas de Machine Learning como Scikit-learn e Prophet — permitiu que os conceitos vistos em sala de aula ganhassem materialidade. Acompanhar de perto todo o processo de tratamento de dados, desde a coleta nas fontes oficiais até a entrega de dashboards interativos, foi extremamente valioso para a formação técnica de todos os integrantes.

Um dos aspectos mais marcantes foi perceber, na prática, o quanto o tratamento de dados é uma etapa central — e desafiadora — de qualquer análise. Lidar com a limpeza, a padronização e a integração de informações vindas de fontes distintas exigiu cuidado e refinamento técnico, e mostrou ao grupo que o sucesso de uma análise preditiva depende fortemente da qualidade do trabalho de preparação. Da mesma forma, ver os modelos de Machine Learning produzirem tendências coerentes com a literatura científica trouxe a sensação concreta de que estávamos respondendo a uma questão social relevante com ferramentas atuais.

Outro ponto de destaque foi o trabalho em equipe. A divisão de tarefas se deu de forma orgânica e equilibrada, com cada integrante assumindo a frente que mais se alinhava ao seu interesse e perfil técnico — Power BI, Databricks, Machine Learning e a frente de pesquisa e documentação. Essa divisão permitiu que cada um aprofundasse o conhecimento em sua área enquanto se mantinha o diálogo constante entre as frentes, o que enriqueceu a experiência coletiva. As reuniões para alinhamento e as decisões tomadas em conjunto reforçaram a colaboração e o respeito mútuo dentro do grupo.

De forma geral, o grupo avalia que os objetivos sociocomunitários propostos — ainda que voltados para um público beneficiário indireto — foram alcançados: produziu-se uma análise consolidada do consumo de antidepressivos pós-pandemia, identificaram-se perfis de uso por grupo clínico e estabeleceu-se uma base técnica replicável para análises futuras. Mais do que entregar artefatos, o projeto permitiu que o grupo experimentasse a satisfação de aplicar conhecimento técnico em um tema socialmente relevante.

3.1.1. Avaliação de reação da parte interessada

Conforme justificado no item 2.2, o projeto não envolveu um público sociocomunitário direto, atuando sobre dados públicos secundários. Por esse motivo, a avaliação de reação foi conduzida de forma adaptada, considerando como parte interessada o próprio docente da disciplina e os colegas de turma presentes na primeira apresentação do projeto, realizada em 02/06.

A reação do docente e da turma foi acompanhada por meio de feedback verbal e perguntas formuladas durante a apresentação, que serviram como instrumento informal de avaliação. As contribuições recebidas nesse momento foram incorporadas ao desenvolvimento posterior do projeto, especialmente nos ajustes da arquitetura de dados, da explicação técnica das bibliotecas e da apresentação visual dos resultados no Power BI.

Como evidência da avaliação, o grupo dispõe dos slides da primeira apresentação, das versões iterativas dos artefatos e das anotações sobre os ajustes realizados após o feedback recebido.

3.2. Relato de Experiência Individual

Esta seção contém o relato individual de cada integrante do grupo. Cada relato deve ser revisado e personalizado pelo respectivo aluno antes da entrega final, com base em sua experiência pessoal no projeto. Os textos a seguir servem como ponto de partida estruturado conforme os itens exigidos no roteiro.

Aluna: Isadora Cândido

3.2.1. Contextualização

Participei do projeto “Uso de Antidepressivos pós-pandemia no BR” da disciplina de Big Data, atuando na frente de pesquisa, preenchimento de documentos e montagem da apresentação. Meu papel envolveu o levantamento das fontes acadêmicas e institucionais utilizadas, a organização das informações coletadas e a estruturação da comunicação visual do projeto.

3.2.2. Metodologia

As atividades foram desenvolvidas remotamente, com encontros regulares do grupo entre 11/05 e 16/06. Trabalhei em conjunto com o Nicollas na frente de documentação e pesquisa, e em diálogo constante com os colegas responsáveis pelas frentes técnicas. As etapas envolveram pesquisa nas bases (FIOCRUZ, CFF/IQVIA, artigos acadêmicos), organização do referencial teórico, montagem dos slides da apresentação e preenchimento do roteiro de extensão.

3.2.3. Resultados e Discussão

A experiência superou minhas expectativas iniciais, especialmente pela oportunidade de aprofundar o entendimento sobre o impacto da pandemia na saúde mental dos brasileiros. Descobri o quanto a pesquisa bibliográfica e a organização documental são essenciais para dar consistência a um projeto técnico. Senti facilidade na organização das informações e da apresentação, e como dificuldade principal a integração entre o conteúdo técnico produzido pelos colegas e a forma de comunicá-lo de maneira clara para um público mais amplo.

3.2.4. Reflexão Aprofundada

Pude perceber, na prática, que o referencial teórico não é apenas formalidade — ele orienta de fato as escolhas analíticas. Os estudos de Correia et al. e de Boavagem & Nogueira, por exemplo, ajudaram a calibrar as variáveis que o grupo escolheu olhar nos dados. A experiência mostrou como teoria e prática se retroalimentam em um projeto de Big Data.

3.2.5. Considerações Finais

Como perspectiva futura, vejo potencial em expandir a análise para outras categorias de psicofármacos (ansiolíticos, antipsicóticos) e em incluir variáveis regionais. Alternativamente, o projeto poderia ter sido desenvolvido com bases de dados abertas adicionais (DATASUS, OpenDataSUS), o que enriqueceria ainda mais a granularidade dos perfis demográficos.

Aluno: Gabriel Gusmão

3.2.1. Contextualização

Atuei no projeto como responsável pela frente de Power BI, desenvolvendo as visualizações que apresentam os resultados da análise. Minha participação envolveu desde a conexão com os dados tratados no Databricks até a construção dos dashboards e o teste preliminar dos primeiros resultados.

3.2.2. Metodologia

As atividades foram realizadas entre 24/05 (teste inicial) e 07/06 (finalização). Trabalhei em diálogo direto com o Enzo, responsável pelo Databricks, para garantir que os dados chegassem ao Power BI no formato adequado, e com a Ruth, responsável pelo Machine Learning, para que os resultados dos modelos pudessem ser incorporados aos dashboards.

3.2.3. Resultados e Discussão

O resultado mais marcante foi a construção do gráfico de distribuição do uso de antidepressivos por grupo clínico, com dez categorias diagnósticas representadas. Ver os dados ganharem forma visual no Power BI foi muito gratificante. Como facilidade, destaco a curva de aprendizado relativamente suave do Power BI; como dificuldade, a etapa de garantir que os dados oriundos do Databricks chegassem corretamente conectados, o que exigiu ajustes em conjunto com o Enzo.

3.2.4. Reflexão Aprofundada

Percebi na prática que a visualização não é a etapa “final” no sentido de simples ilustração — ela é parte ativa da análise, pois revela padrões que tabelas não mostram. A integração entre Databricks e Power BI mostrou como o ecossistema de Big Data funciona em camadas conectadas, e não como ferramentas isoladas.

3.2.5. Considerações Finais

Como evolução futura, seria interessante incorporar atualizações automáticas dos dashboards conforme novos dados forem disponibilizados pelas fontes oficiais. Como alternativa tecnológica, ferramentas como o Tableau ou o Looker Studio poderiam ter sido utilizadas em substituição ao Power BI, oferecendo outras possibilidades de visualização.

Aluno: Enzo Laranjeira

3.2.1. Contextualização

Fui o responsável pela frente de Databricks, atuando na configuração do cluster, na construção do pipeline de dados e nas etapas de tratamento. Foi a frente técnica mais densa do projeto e a que mais me aproximou do conceito central da disciplina de Big Data.

3.2.2. Metodologia

Iniciei meu trabalho na semana de coleta de dados (11/05 a 15/05), seguindo para a construção do pipeline e tratamento em 19/05. Trabalhei em coordenação com a Ruth (Machine Learning), que consumiu os dados tratados por mim, e com o Gabriel (Power BI), que recebeu a saída final dos dados.

3.2.3. Resultados e Discussão

Conseguir colocar o pipeline funcionando de ponta a ponta — leitura das fontes, tratamento e disponibilização para as próximas etapas — foi a maior conquista pessoal no projeto. A principal dificuldade foi a padronização dos dados, vindos de fontes com formatos distintos. Como facilidade, destaco a flexibilidade do Databricks para experimentação rápida e iterativa.

3.2.4. Reflexão Aprofundada

Apreendi que o trabalho de engenharia de dados é tão importante quanto a modelagem em si — sem dados bem tratados, nenhum modelo de Machine Learning produz resultados confiáveis. A teoria sobre arquitetura em camadas, vista em aula, ganhou sentido concreto ao construir cada uma delas na prática.

3.2.5. Considerações Finais

Em projetos futuros, gostaria de explorar a evolução do pipeline para um modelo realmente em tempo real, com ingestão contínua. Como alternativa tecnológica, ferramentas como Apache Airflow ou Snowflake poderiam ter sido empregadas, ampliando o leque de aprendizado.

Aluna: Ruth Cavalcante

3.2.1. Contextualização

Atuei como responsável pela frente de Machine Learning, aplicando as bibliotecas Scikit-learn e Prophet sobre os dados tratados no Databricks. Foi a frente que mais me desafiou intelectualmente e que mais aprofundou meu entendimento sobre análise preditiva.

3.2.2. Metodologia

Iniciei o trabalho a partir de 19/05, após o tratamento inicial dos dados pelo Enzo, e finalizei os modelos em 03/06. A regressão linear (Scikit-learn) foi aplicada para identificar a tendência de crescimento do consumo, e o Prophet foi utilizado para prever o comportamento futuro, considerando o histórico pós-pandemia.

3.2.3. Resultados e Discussão

Ver a regressão produzir uma linha de tendência clara, coerente com o crescimento descrito na literatura, foi um momento de grande satisfação. O Prophet, por sua vez, revelou padrões interessantes ao projetar o consumo futuro. Como dificuldade, destaco o ajuste fino dos parâmetros do Prophet; como facilidade, a documentação e a comunidade ativa do Scikit-learn.

3.2.4. Reflexão Aprofundada

Compreendi de forma prática que “Machine Learning” não é uma caixa preta, e sim um conjunto de escolhas estatísticas conscientes. A regressão linear, por exemplo, parece simples, mas comunica de forma muito clara a magnitude de um fenômeno social — algo que dialoga diretamente com o que vimos no referencial teórico do projeto.

3.2.5. Considerações Finais

Como evolução, vejo possibilidade de incorporar modelos mais sofisticados (ARIMA, redes neurais recorrentes) para refinar as previsões. Alternativamente, frameworks como TensorFlow ou PyTorch poderiam ter sido utilizados em uma abordagem de deep learning, embora exigissem volumes de dados maiores do que os disponíveis.

Aluno: Nicollas da Silva

3.2.1. Contextualização

Atuei junto à Isadora na frente de pesquisa, preenchimento de documentos e montagem da apresentação. Foi um papel central de integração, garantindo que o trabalho técnico do grupo fosse traduzido em um conteúdo organizado e comunicável.

3.2.2. Metodologia

Trabalhei ao longo de todo o período do projeto (11/05 a 16/06), com intensidade especial nas semanas de montagem da apresentação (25/05) e de finalização do documento. Mantive interlocução constante com os colegas das frentes técnicas para captar o conteúdo a ser comunicado nos slides e neste documento.

3.2.3. Resultados e Discussão

Ver o material consolidado em uma apresentação visualmente coerente, e perceber que as ideias técnicas chegaram com clareza ao público da primeira apresentação, foi muito gratificante. Como dificuldade, destaco a tradução de conceitos técnicos (como regressão linear e séries temporais) para uma linguagem acessível; como facilidade, o entrosamento do grupo, que tornou o trabalho colaborativo fluido.

3.2.4. Reflexão Aprofundada

Apreendi que a comunicação é parte indissociável de qualquer projeto técnico. Um trabalho de Big Data bem executado, mas mal comunicado, perde grande parte de seu valor. O equilíbrio entre rigor técnico e clareza comunicativa foi um aprendizado central para mim.

3.2.5. Considerações Finais

Em projetos futuros, vejo espaço para o desenvolvimento de uma narrativa visual ainda mais robusta — talvez com uma versão pública dos dashboards para o cidadão comum. Como alternativa, ferramentas como Notion, Canva ou plataformas de storytelling de dados poderiam complementar a comunicação dos resultados.

Florianópolis/SC, junho de 2026.